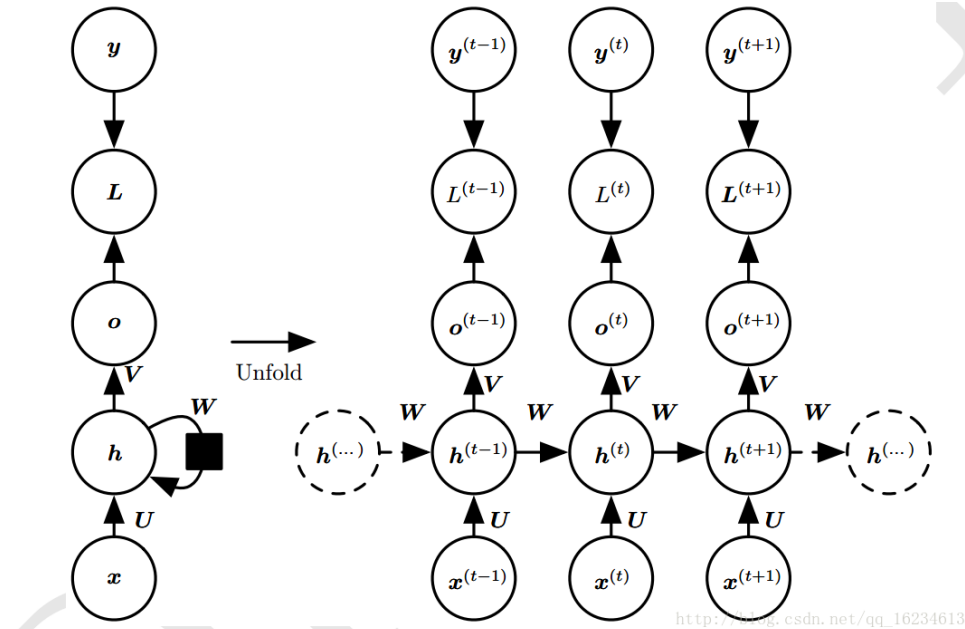


RNN-LSTM-GRU 模型

1. RNN 模型

循环神经网络又叫做 RNN(Recurrent Neural Networks), 主要用来处理连续序列的样本。
下图是一个标准的 RNN 网络:



在 RNN 网络中, 首先介绍下各个符号的含义: t 表示时间序列; x 代表输入, 是一个 n 行一列的向量; U 代表 x 的权重, 是一个 m 行 n 列的矩阵; h 代表隐藏状态, 是一个 m 行一列的向量; W 和 V 代表权重, 分别是一个 m 行 m 列的矩阵和一个 k 行 m 列的矩阵; o 是一个 k 行一列的向量; \hat{y}' 和 y' 代表 t 时刻预测输出和真实输出, 都是一个 k 行一列的向量;

b 和 c 分别是 m 行一列和 k 行一列的向量; L' 代表 t 时刻的损失值 (标量), 是一个交叉熵损失函数。

有了上面模型符号的介绍, 下面就来介绍 RNN 的前向传播过程。对于任意的隐藏状态 h' 是由 x' 和 h'^{-1} 决定, 即:

$$h' = f(z') = f(Ux' + Wh'^{-1} + b)$$

上式中, f 代表 \tanh 函数。 o' 是 h' 由决定, 即:

$$o' = Vh' + c$$

因此, 预测输出 \hat{y}' 为:

$$\hat{y}' = f(o')$$

上式中, f 代表 softmax 函数。由于 L' 代表 t 时刻的损失函数, 因此最终的损失函数为:

$$L = \sum_{t=1}^{\tau} L'$$

上式中, τ 代表最后一个时刻。

在 RNN 模型中, 模型参数 U 、 V 、 W 、 b 和 c 是共享的, 因此可以根据 RNN 的反向传

播算法 BPTT(back-propagation through time)计算各个模型参数的值。首先，计算 L 对 \mathbf{V} 和 \mathbf{c} 的偏导，即：

$$\begin{aligned}\frac{\partial L}{\partial \mathbf{c}} &= \sum_{t=1}^{\tau} \frac{\partial L^t}{\partial \mathbf{c}} = \sum_{t=1}^{\tau} \frac{\partial L^t}{\partial \mathbf{o}^t} \frac{\partial \mathbf{o}^t}{\partial \mathbf{c}} = \sum_{t=1}^{\tau} \hat{\mathbf{y}}^t - \mathbf{y}^t \\ \frac{\partial L}{\partial \mathbf{V}} &= \sum_{t=1}^{\tau} \frac{\partial L^t}{\partial \mathbf{V}} = \sum_{t=1}^{\tau} \frac{\partial L^t}{\partial \mathbf{o}^t} \frac{\partial \mathbf{o}^t}{\partial \mathbf{V}} = \sum_{t=1}^{\tau} (\hat{\mathbf{y}}^t - \mathbf{y}^t) (\mathbf{h}^t)^T\end{aligned}$$

然后计算 \mathbf{W} 、 \mathbf{U} 和 \mathbf{b} 的梯度，定义序列索引 t 位置的隐藏状态的梯度为：

$$\boldsymbol{\delta}^t = \frac{\partial L}{\partial \mathbf{h}^t}$$

上式中， $\boldsymbol{\delta}^t$ 是一个 m 行一列的向量。当 t 不等于 τ 时，

$$\begin{aligned}\boldsymbol{\delta}^t &= \frac{\partial L}{\partial \mathbf{o}^t} \frac{\partial \mathbf{o}^t}{\partial \mathbf{h}^t} + \frac{\partial L}{\partial \mathbf{h}^{t+1}} \frac{\partial \mathbf{h}^{t+1}}{\partial \mathbf{h}^t} \\ &= \mathbf{V}^T (\hat{\mathbf{y}}^t - \mathbf{y}^t) + \frac{\partial (\boldsymbol{\delta}^{t+1})^T \mathbf{h}^{t+1}}{\partial \mathbf{h}^t} \\ &= \mathbf{V}^T (\hat{\mathbf{y}}^t - \mathbf{y}^t) + \mathbf{W}^T (\boldsymbol{\delta}^{t+1} \odot \mathbf{f}'(\mathbf{z}^t)) \\ &= \mathbf{V}^T (\hat{\mathbf{y}}^t - \mathbf{y}^t) + \mathbf{W}^T \text{diag}(\delta_1^{t+1}, \delta_2^{t+1}, \dots, \delta_m^{t+1}) \mathbf{f}'(\mathbf{z}^t) \\ &= \mathbf{V}^T (\hat{\mathbf{y}}^t - \mathbf{y}^t) + \mathbf{W}^T \text{diag}(1 - (h_1^{t+1})^2, 1 - (h_2^{t+1})^2, \dots, 1 - (h_m^{t+1})^2) \boldsymbol{\delta}^{t+1}\end{aligned}$$

上式中， $\text{diag}(\ast)$ 表示对角矩阵， δ_i^{t+1} ($i=1,2,\dots,m$)和 h_i^{t+1} ($i=1,2,\dots,m$)分别是 $\boldsymbol{\delta}^{t+1}$ 和 \mathbf{h}^{t+1} 中的每个元素。当 t 等于 τ 时，

$$\boldsymbol{\delta}^\tau = \frac{\partial L}{\partial \mathbf{o}^\tau} \frac{\partial \mathbf{o}^\tau}{\partial \mathbf{h}^\tau} = \mathbf{V}^T (\hat{\mathbf{y}}^\tau - \mathbf{y}^\tau)$$

因此， \mathbf{W} 、 \mathbf{U} 和 \mathbf{b} 的梯度计算表达式为：

$$\begin{aligned}\frac{\partial L}{\partial \mathbf{W}} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{h}^t} \frac{\partial \mathbf{h}^t}{\partial \mathbf{W}} = \sum_{t=1}^{\tau} \text{diag}(1 - (h_1^{t+1})^2, 1 - (h_2^{t+1})^2, \dots, 1 - (h_m^{t+1})^2) \boldsymbol{\delta}^{t+1} (\mathbf{h}^{t-1})^T \\ \frac{\partial L}{\partial \mathbf{b}} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{h}^t} \frac{\partial \mathbf{h}^t}{\partial \mathbf{b}} = \sum_{t=1}^{\tau} \text{diag}(1 - (h_1^{t+1})^2, 1 - (h_2^{t+1})^2, \dots, 1 - (h_m^{t+1})^2) \boldsymbol{\delta}^{t+1} \\ \frac{\partial L}{\partial \mathbf{U}} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{h}^t} \frac{\partial \mathbf{h}^t}{\partial \mathbf{U}} = \sum_{t=1}^{\tau} \text{diag}(1 - (h_1^{t+1})^2, 1 - (h_2^{t+1})^2, \dots, 1 - (h_m^{t+1})^2) \boldsymbol{\delta}^{t+1} (\mathbf{x}^t)^T\end{aligned}$$

最后，根据如下公式更新 RNN 模型中的参数：


$$\theta_{\text{update}} = \theta - \alpha \frac{\partial L}{\partial \theta}$$

上式中， θ 代表的是模型参数 \mathbf{U} 、 \mathbf{V} 、 \mathbf{W} 、 \mathbf{b} 和 \mathbf{c} ， α 代表学习率， θ_{update} 代表更新完以后的参数。


但是在 RNN 模型中会出现梯度爆炸和梯度消失的问题。出现梯度消失，是因为更新模型参数 \mathbf{W} 、 \mathbf{U} 和 \mathbf{b} 时，都与之前的状态有关，而 \tanh 函数的导数在 0 到 1 之间，经过多次迭代相乘，极容易出现梯度消失。出现梯度爆炸，是因为更新模型参数 \mathbf{W} 、 \mathbf{U} 和 \mathbf{b} 时，也都与之前的状态有关，当 \tanh 函数的导数不是特别小时同时模型参数 \mathbf{W} 又很大，经过多次迭代相乘，就会出现梯度爆炸，这也是梯度爆炸出现概率比较小的原因。

2. LSTM 模型

LSTM(Long Short-Term Memory)又叫长短期记忆，是 RNN 模型的一种改进，主要为了解决 RNN 模型的梯度消失问题。下面是 LSTM 的结构图：




上图中， σ 表示的是 sigmoid 函数。下面深度分析 LSTM 模型，首先是遗忘门，其结构如下图：



上图中用数学表达式为：

$$f^t = \sigma(W_f h^{t-1} + U_f x^t + b_f)$$

上式中， f 是 m 行 1 列， W_f 是 m 行 m 列， h^{t-1} 是 m 行 1 列， U_f 是 m 行 n 列， x^t 是 n 行 1 列， b_f 是 m 行 1 列。其次是输入门，其结构如下图：




上图中用数学表达式为：

$$i^t = \sigma(W_i h^{t-1} + U_i x^t + b_i)$$

$$a^t = \tanh(W_a h^{t-1} + U_a x^t + b_a)$$

上式中， i^t 是 m 行 1 列， W_i 是 m 行 m 列， U_i 是 m 行 n 列， b_i 是 m 行 1 列， $\tilde{C}_t = a^t$ ， a^t 是


m 行 1 列， \mathbf{W}_a 是 m 行 m 列， \mathbf{U}_a 是 m 行 n 列， \mathbf{b}_a 是 m 行 1 列。其次是状态更新，其结构如下图：



上图中用数学表达式为：

$$\mathbf{C}^t = \mathbf{C}^{t-1} \odot \mathbf{f}^t + \mathbf{i}^t \odot \mathbf{a}^t$$

最后是输出门，其结构如下图：



上图中用数学表达式为：

$$\mathbf{o}^t = \sigma(\mathbf{W}_o \mathbf{h}^{t-1} + \mathbf{U}_o \mathbf{x}^t + \mathbf{b}_o)$$

$$\mathbf{h}^t = \mathbf{o}^t \odot \tanh(\mathbf{C}^t)$$

上式中， \mathbf{o}^t 是 m 行 1 列， \mathbf{W}_o 是 m 行 m 列， \mathbf{U}_o 是 m 行 n 列， \mathbf{b}_o 是 m 行 1 列。因此，LSTM 模型的前向传播为：

(1).遗忘门输出：

$$\mathbf{f}^t = \sigma(\mathbf{W}_f \mathbf{h}^{t-1} + \mathbf{U}_f \mathbf{x}^t + \mathbf{b}_f)$$

(2).输入门输出：

$$\mathbf{i}^t = \sigma(\mathbf{W}_i \mathbf{h}^{t-1} + \mathbf{U}_i \mathbf{x}^t + \mathbf{b}_i)$$

$$\mathbf{a}^t = \tanh(\mathbf{W}_a \mathbf{h}^{t-1} + \mathbf{U}_a \mathbf{x}^t + \mathbf{b}_a)$$

(3).状态更新：

$$\mathbf{C}^t = \mathbf{C}^{t-1} \odot \mathbf{f}^t + \mathbf{i}^t \odot \mathbf{a}^t$$

(4).输出门输出：

$$\mathbf{o}^t = \sigma(\mathbf{W}_o \mathbf{h}^{t-1} + \mathbf{U}_o \mathbf{x}^t + \mathbf{b}_o)$$

$$\mathbf{h}^t = \mathbf{o}^t \odot \tanh(\mathbf{C}^t)$$

(5).预测输出:

$$\begin{aligned} \mathbf{d}^t &= \mathbf{V}\mathbf{h}^t + \mathbf{c} \\ \hat{\mathbf{y}}^t &= \text{softmax}(\mathbf{d}^t) \end{aligned}$$

上式中, \mathbf{b}^t 是 k 行 1 列, 相当于 RNN 模型中的 \mathbf{o}^t , $\hat{\mathbf{y}}^t$ 是 k 行 1 列, \mathbf{V} 是 k 行 m 列, \mathbf{c} 是 k 行 1 列。通过上面的描述, LSTM 算法中更新的参数为: \mathbf{W}_f 、 \mathbf{U}_f 、 \mathbf{b}_f 、 \mathbf{W}_i 、 \mathbf{U}_i 、 \mathbf{b}_i 、 \mathbf{W}_a 、 \mathbf{U}_a 、 \mathbf{b}_a 、 \mathbf{W}_o 、 \mathbf{U}_o 、 \mathbf{b}_o 、 \mathbf{V} 和 \mathbf{c} , 因此通过 BPTT 更新这些参数, 首先, 计算 L 对 \mathbf{V} 和 \mathbf{c} 的偏导, 即:

$$\begin{aligned} \frac{\partial L}{\partial \mathbf{c}} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{c}} = \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{d}^t} \frac{\partial \mathbf{d}^t}{\partial \mathbf{c}} = \sum_{t=1}^{\tau} \hat{\mathbf{y}}^t - \mathbf{y}^t \\ \frac{\partial L}{\partial \mathbf{V}} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{V}} = \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{d}^t} \frac{\partial \mathbf{d}^t}{\partial \mathbf{V}} = \sum_{t=1}^{\tau} (\hat{\mathbf{y}}^t - \mathbf{y}^t) (\mathbf{h}^t)^T \end{aligned}$$

然后定义两个变量, 如下:

$$\begin{aligned} \delta_h^t &= \frac{\partial L}{\partial \mathbf{h}^t} \\ \delta_c^t &= \frac{\partial L}{\partial \mathbf{c}^t} \end{aligned}$$

当 t 等于 τ (最后一个时刻), 则:

$$\begin{aligned} \delta_h^\tau &= \frac{\partial L}{\partial \mathbf{d}^\tau} \frac{\partial \mathbf{d}^\tau}{\partial \mathbf{h}^\tau} = \mathbf{V}^T (\hat{\mathbf{y}}^\tau - \mathbf{y}^\tau) \\ \delta_c^\tau &= \frac{\partial L}{\partial \mathbf{h}^\tau} \frac{\partial \mathbf{h}^\tau}{\partial \mathbf{C}^\tau} = \delta_h^\tau \odot \mathbf{o}^\tau \odot (1 - \tanh(\mathbf{C}^\tau) \odot \tanh(\mathbf{C}^\tau)) \end{aligned}$$

当 t 不等于 τ , 则:

$$\begin{aligned} \delta_h^t &= \frac{\partial L}{\partial \mathbf{d}^t} \frac{\partial \mathbf{d}^t}{\partial \mathbf{h}^t} = \mathbf{V}^T (\hat{\mathbf{y}}^t - \mathbf{y}^t) \\ \delta_c^t &= \frac{\partial L}{\partial \mathbf{C}^{t+1}} \frac{\partial \mathbf{C}^{t+1}}{\partial \mathbf{C}^t} + \frac{\partial L}{\partial \mathbf{h}^t} \frac{\partial \mathbf{h}^t}{\partial \mathbf{C}^t} = \delta_c^{t+1} \odot \mathbf{f}^{t+1} + \delta_h^t \odot \mathbf{o}^t \odot (1 - \tanh(\mathbf{C}^t) \odot \tanh(\mathbf{C}^t)) \end{aligned}$$

因此, 其他的参数更新的为:

$$\begin{aligned} \frac{\partial L}{\partial \mathbf{W}_f} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{C}^t} \frac{\partial \mathbf{C}^t}{\partial \mathbf{f}^t} \frac{\partial \mathbf{f}^t}{\partial \mathbf{W}_f} = \sum_{t=1}^{\tau} \delta_c^t \odot \mathbf{C}^{t-1} \odot \mathbf{f}^t \odot (1 - \mathbf{f}^t) (\mathbf{h}^{t-1})^T \\ \frac{\partial L}{\partial \mathbf{U}_f} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{C}^t} \frac{\partial \mathbf{C}^t}{\partial \mathbf{f}^t} \frac{\partial \mathbf{f}^t}{\partial \mathbf{U}_f} = \sum_{t=1}^{\tau} \delta_c^t \odot \mathbf{C}^{t-1} \odot \mathbf{f}^t \odot (1 - \mathbf{f}^t) (\mathbf{x}^t)^T \\ \frac{\partial L}{\partial \mathbf{b}_f} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{C}^t} \frac{\partial \mathbf{C}^t}{\partial \mathbf{f}^t} \frac{\partial \mathbf{f}^t}{\partial \mathbf{b}_f} = \sum_{t=1}^{\tau} \delta_c^t \odot \mathbf{C}^{t-1} \odot \mathbf{f}^t \odot (1 - \mathbf{f}^t) \\ \frac{\partial L}{\partial \mathbf{W}_i} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{C}^t} \frac{\partial \mathbf{C}^t}{\partial \mathbf{i}^t} \frac{\partial \mathbf{i}^t}{\partial \mathbf{W}_i} = \sum_{t=1}^{\tau} \delta_c^t \odot \mathbf{a}^t \odot \mathbf{i}^t \odot (1 - \mathbf{i}^t) (\mathbf{h}^{t-1})^T \end{aligned}$$

$$\frac{\partial L}{\partial U_i} = \sum_{t=1}^{\tau} \frac{\partial L}{\partial C^t} \frac{\partial C^t}{\partial i^t} \frac{\partial i^t}{\partial U_i} = \sum_{t=1}^{\tau} \delta_c^t \odot a^t \odot i^t \odot (1-i^t) (x^t)^T$$

$$\frac{\partial L}{\partial b_i} = \sum_{t=1}^{\tau} \frac{\partial L}{\partial C^t} \frac{\partial C^t}{\partial i^t} \frac{\partial i^t}{\partial b_i} = \sum_{t=1}^{\tau} \delta_c^t \odot a^t \odot i^t \odot (1-i^t)$$

$$\frac{\partial L}{\partial W_a} = \sum_{t=1}^{\tau} \frac{\partial L}{\partial C^t} \frac{\partial C^t}{\partial a^t} \frac{\partial a^t}{\partial W_a} = \sum_{t=1}^{\tau} \delta_c^t \odot i^t \odot (1-a^t \odot a^t) (h^{t-1})^T$$

$$\frac{\partial L}{\partial U_a} = \sum_{t=1}^{\tau} \frac{\partial L}{\partial C^t} \frac{\partial C^t}{\partial a^t} \frac{\partial a^t}{\partial U_a} = \sum_{t=1}^{\tau} \delta_c^t \odot i^t \odot (1-a^t \odot a^t) (x^t)^T$$

$$\frac{\partial L}{\partial b_a} = \sum_{t=1}^{\tau} \frac{\partial L}{\partial C^t} \frac{\partial C^t}{\partial a^t} \frac{\partial a^t}{\partial b_a} = \sum_{t=1}^{\tau} \delta_c^t \odot i^t \odot (1-a^t \odot a^t)$$

$$\frac{\partial L}{\partial W_o} = \sum_{t=1}^{\tau} \frac{\partial L}{\partial h^t} \frac{\partial h^t}{\partial o^t} \frac{\partial o^t}{\partial W_o} = \sum_{t=1}^{\tau} \delta_h^t \odot \tanh(C^t) \odot (1-o^t \odot o^t) (h^{t-1})^T$$


$$\frac{\partial L}{\partial U_o} = \sum_{t=1}^{\tau} \frac{\partial L}{\partial h^t} \frac{\partial h^t}{\partial o^t} \frac{\partial o^t}{\partial U_o} = \sum_{t=1}^{\tau} \delta_h^t \odot \tanh(C^t) \odot (1-o^t \odot o^t) (x^t)^T$$

$$\frac{\partial L}{\partial b_o} = \sum_{t=1}^{\tau} \frac{\partial L}{\partial h^t} \frac{\partial h^t}{\partial o^t} \frac{\partial o^t}{\partial b_o} = \sum_{t=1}^{\tau} \delta_h^t \odot \tanh(C^t) \odot (1-o^t \odot o^t)$$

最后，根据 RNN 模型更新参数的方式更新参数。LSTM 模型之所以可以减小(不是解决)RNN 的梯度消失问题，是因为 LSTM 模型引入了门控开关(模型里面的 sigmoid 函数起着门控开关的作用)和 Hadamard 积，这可以防止对模型参数的偏导进行矩阵连乘，从而可以减小梯度消失。

3. GRU 模型

GRU(Gated Recurrent Unit)又叫门控循环单元，是 LSTM 模型的一种变体，同样是为了解决 RNN 模型的梯度消失问题。下面是 GRU 的结构图：



上图中， σ 表示的是 sigmoid 函数。因此 GRU 模型的前向传播为：

$$\begin{aligned}
\mathbf{z}^t &= \sigma(\mathbf{W}_z \mathbf{h}^{t-1} + \mathbf{U}_z \mathbf{x}^t + \mathbf{b}_z) \\
\mathbf{r}^t &= \sigma(\mathbf{W}_r \mathbf{h}^{t-1} + \mathbf{U}_r \mathbf{x}^t + \mathbf{b}_r) \\
\mathbf{s}^t &= \tanh(\mathbf{W}_s (\mathbf{h}^{t-1} \odot \mathbf{r}^t) + \mathbf{U}_s \mathbf{x}^t + \mathbf{b}_s) \\
\mathbf{h}^t &= (1 - \mathbf{z}^t) \odot \mathbf{h}^{t-1} + \mathbf{z}^t \odot \mathbf{s}^t \\
\mathbf{o}^t &= \mathbf{V} \mathbf{h}^t + \mathbf{c} \\
\hat{\mathbf{y}}^t &= \text{softmax}(\mathbf{o}^t)
\end{aligned}$$

上式中, \mathbf{W}_z 是 m 行 m 列, \mathbf{h}^{t-1} 是 m 行 1 列, \mathbf{U}_z 是 m 行 n 列, \mathbf{x}_t 是 n 行 1 列, \mathbf{b}_z 是 m 行 1 列, \mathbf{z}^t 是 m 行 1 列, \mathbf{W}_r 是 m 行 m 列, \mathbf{U}_r 是 m 行 n 列, \mathbf{b}_r 是 m 行 1 列, \mathbf{r}^t 是 m 行 1 列, \mathbf{W}_s 是 m 行 m 列, \mathbf{U}_s 是 m 行 n 列, \mathbf{b}_s 是 m 行 1 列, \mathbf{s}^t 等于 $\tilde{\mathbf{h}}^t$, \mathbf{s}^t 是 m 行 1 列, $\hat{\mathbf{y}}^t$ 是 k 行 1 列, \mathbf{V} 是 k 行 m 列, \mathbf{c} 是 k 行 1 列。因此通过 BPTT 更新这些参数, 首先, 计算 L 对 \mathbf{V} 和 \mathbf{c} 的偏导, 即:

$$\begin{aligned}
\frac{\partial L}{\partial \mathbf{c}} &= \sum_{t=1}^{\tau} \frac{\partial L^t}{\partial \mathbf{c}} = \sum_{t=1}^{\tau} \frac{\partial L^t}{\partial \mathbf{o}^t} \frac{\partial \mathbf{o}^t}{\partial \mathbf{c}} = \sum_{t=1}^{\tau} \hat{\mathbf{y}}^t - \mathbf{y}^t \\
\frac{\partial L}{\partial \mathbf{V}} &= \sum_{t=1}^{\tau} \frac{\partial L^t}{\partial \mathbf{V}} = \sum_{t=1}^{\tau} \frac{\partial L^t}{\partial \mathbf{o}^t} \frac{\partial \mathbf{o}^t}{\partial \mathbf{V}} = \sum_{t=1}^{\tau} (\hat{\mathbf{y}}^t - \mathbf{y}^t) (\mathbf{h}^t)^T
\end{aligned}$$

然后计算 \mathbf{W} 、 \mathbf{U} 和 \mathbf{b} 的梯度, 定义序列索引 t 位置的隐藏状态的梯度为:

$$\boldsymbol{\delta}^t = \frac{\partial L}{\partial \mathbf{h}^t}$$

上式中, $\boldsymbol{\delta}^t$ 是一个 m 行 1 列的向量。当 t 不等于 τ (最后一个时刻) 时,

$$\begin{aligned}
\boldsymbol{\delta}^t &= \frac{\partial L}{\partial \mathbf{o}^t} \frac{\partial \mathbf{o}^t}{\partial \mathbf{h}^t} + \frac{\partial L}{\partial \mathbf{h}^{t+1}} \frac{\partial \mathbf{h}^{t+1}}{\partial \mathbf{h}^t} \\
&= \mathbf{V}^T (\hat{\mathbf{y}}^t - \mathbf{y}^t) + \boldsymbol{\delta}^{t+1} (1 - \mathbf{z}^t)
\end{aligned}$$

当 t 等于 τ 时,

$$\boldsymbol{\delta}^\tau = \frac{\partial L}{\partial \mathbf{o}^\tau} \frac{\partial \mathbf{o}^\tau}{\partial \mathbf{h}^\tau} = \mathbf{V}^T (\hat{\mathbf{y}}^\tau - \mathbf{y}^\tau)$$

因此, \mathbf{W}_z 、 \mathbf{U}_z 、 \mathbf{b}_z 、 \mathbf{W}_r 、 \mathbf{U}_r 、 \mathbf{b}_r 、 \mathbf{W}_s 、 \mathbf{U}_s 和 \mathbf{b}_s 的更新方式为:

$$\begin{aligned}
\frac{\partial L}{\partial \mathbf{W}_z} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{h}^t} \frac{\partial \mathbf{h}^t}{\partial \mathbf{z}^t} \frac{\partial \mathbf{z}^t}{\partial \mathbf{W}_z} = \sum_{t=1}^{\tau} \boldsymbol{\delta}^t \odot (\mathbf{s}^t - \mathbf{h}^{t-1}) \odot (\mathbf{h}^{t-1})^T \\
\frac{\partial L}{\partial \mathbf{U}_z} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{h}^t} \frac{\partial \mathbf{h}^t}{\partial \mathbf{z}^t} \frac{\partial \mathbf{z}^t}{\partial \mathbf{U}_z} = \sum_{t=1}^{\tau} \boldsymbol{\delta}^t \odot (\mathbf{s}^t - \mathbf{h}^{t-1}) \odot (\mathbf{x}^t)^T \\
\frac{\partial L}{\partial \mathbf{b}_z} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{h}^t} \frac{\partial \mathbf{h}^t}{\partial \mathbf{z}^t} \frac{\partial \mathbf{z}^t}{\partial \mathbf{b}_z} = \sum_{t=1}^{\tau} \boldsymbol{\delta}^t \odot (\mathbf{s}^t - \mathbf{h}^{t-1})
\end{aligned}$$

$$\begin{aligned}
\frac{\partial L}{\partial \mathbf{W}_r} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{h}^t} \frac{\partial \mathbf{h}^t}{\partial \mathbf{s}^t} \frac{\partial \mathbf{s}^t}{\partial \mathbf{r}^t} \frac{\partial \mathbf{r}^t}{\partial \mathbf{W}_r} = \sum_{t=1}^{\tau} \boldsymbol{\delta}^t \odot \mathbf{z}^t \frac{\partial \mathbf{s}^t}{\partial \mathbf{r}^t} \frac{\partial \mathbf{r}^t}{\partial \mathbf{W}_r} \\
&= \sum_{t=1}^{\tau} \frac{\partial (\boldsymbol{\delta}^t \odot \mathbf{z}^t)^T \mathbf{s}^t}{\partial \mathbf{r}^t} \frac{\partial \mathbf{r}^t}{\partial \mathbf{W}_r} = \sum_{t=1}^{\tau} (\mathbf{W}_s)^T (\boldsymbol{\delta}^t \odot \mathbf{z}^t \odot (1 - \mathbf{s}^t \odot \mathbf{s}^t)) \odot \mathbf{h}^{t-1} \frac{\partial \mathbf{r}^t}{\partial \mathbf{W}_r} \\
&= \sum_{t=1}^{\tau} (\mathbf{W}_s)^T (\boldsymbol{\delta}^t \odot \mathbf{z}^t \odot (1 - \mathbf{s}^t \odot \mathbf{s}^t)) \odot \mathbf{h}^{t-1} \odot \mathbf{r}^t \odot (1 - \mathbf{r}^t) (\mathbf{h}^{t-1})^T \\
\\
\frac{\partial L}{\partial \mathbf{U}_r} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{h}^t} \frac{\partial \mathbf{h}^t}{\partial \mathbf{s}^t} \frac{\partial \mathbf{s}^t}{\partial \mathbf{r}^t} \frac{\partial \mathbf{r}^t}{\partial \mathbf{U}_r} = \sum_{t=1}^{\tau} \boldsymbol{\delta}^t \odot \mathbf{z}^t \frac{\partial \mathbf{s}^t}{\partial \mathbf{r}^t} \frac{\partial \mathbf{r}^t}{\partial \mathbf{U}_r} \\
&= \sum_{t=1}^{\tau} \frac{\partial (\boldsymbol{\delta}^t \odot \mathbf{z}^t)^T \mathbf{s}^t}{\partial \mathbf{r}^t} \frac{\partial \mathbf{r}^t}{\partial \mathbf{U}_r} = \sum_{t=1}^{\tau} (\mathbf{W}_s)^T (\boldsymbol{\delta}^t \odot \mathbf{z}^t \odot (1 - \mathbf{s}^t \odot \mathbf{s}^t)) \odot \mathbf{h}^{t-1} \frac{\partial \mathbf{r}^t}{\partial \mathbf{U}_r} \\
&= \sum_{t=1}^{\tau} (\mathbf{W}_s)^T (\boldsymbol{\delta}^t \odot \mathbf{z}^t \odot (1 - \mathbf{s}^t \odot \mathbf{s}^t)) \odot \mathbf{h}^{t-1} \odot \mathbf{r}^t \odot (1 - \mathbf{r}^t) (\mathbf{x}^t)^T \\
\\
\frac{\partial L}{\partial \mathbf{b}_r} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{h}^t} \frac{\partial \mathbf{h}^t}{\partial \mathbf{s}^t} \frac{\partial \mathbf{s}^t}{\partial \mathbf{r}^t} \frac{\partial \mathbf{r}^t}{\partial \mathbf{b}_r} = \sum_{t=1}^{\tau} \boldsymbol{\delta}^t \odot \mathbf{z}^t \frac{\partial \mathbf{s}^t}{\partial \mathbf{r}^t} \frac{\partial \mathbf{r}^t}{\partial \mathbf{b}_r} \\
&= \sum_{t=1}^{\tau} \frac{\partial (\boldsymbol{\delta}^t \odot \mathbf{z}^t)^T \mathbf{s}^t}{\partial \mathbf{r}^t} \frac{\partial \mathbf{r}^t}{\partial \mathbf{b}_r} = \sum_{t=1}^{\tau} (\mathbf{W}_s)^T (\boldsymbol{\delta}^t \odot \mathbf{z}^t \odot (1 - \mathbf{s}^t \odot \mathbf{s}^t)) \odot \mathbf{h}^{t-1} \frac{\partial \mathbf{r}^t}{\partial \mathbf{b}_r} \\
&= \sum_{t=1}^{\tau} (\mathbf{W}_s)^T (\boldsymbol{\delta}^t \odot \mathbf{z}^t \odot (1 - \mathbf{s}^t \odot \mathbf{s}^t)) \odot \mathbf{h}^{t-1} \odot \mathbf{r}^t \odot (1 - \mathbf{r}^t) \\
\\
\frac{\partial L}{\partial \mathbf{W}_s} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{h}^t} \frac{\partial \mathbf{h}^t}{\partial \mathbf{s}^t} \frac{\partial \mathbf{s}^t}{\partial \mathbf{W}_s} = \sum_{t=1}^{\tau} \boldsymbol{\delta}^t \odot \mathbf{z}^t \odot (1 - \mathbf{s}^t \odot \mathbf{s}^t) (\mathbf{h}^{t-1} \odot \mathbf{r}^t)^T \\
\\
\frac{\partial L}{\partial \mathbf{U}_s} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{h}^t} \frac{\partial \mathbf{h}^t}{\partial \mathbf{s}^t} \frac{\partial \mathbf{s}^t}{\partial \mathbf{U}_s} = \sum_{t=1}^{\tau} \boldsymbol{\delta}^t \odot \mathbf{z}^t \odot (1 - \mathbf{s}^t \odot \mathbf{s}^t) (\mathbf{x}^t)^T \\
\\
\frac{\partial L}{\partial \mathbf{b}_s} &= \sum_{t=1}^{\tau} \frac{\partial L}{\partial \mathbf{h}^t} \frac{\partial \mathbf{h}^t}{\partial \mathbf{s}^t} \frac{\partial \mathbf{s}^t}{\partial \mathbf{b}_s} = \sum_{t=1}^{\tau} \boldsymbol{\delta}^t \odot \mathbf{z}^t \odot (1 - \mathbf{s}^t \odot \mathbf{s}^t)
\end{aligned}$$

最后，根据 RNN 模型更新参数的方式更新参数。GRU 模型之所以可以减小(不是解决)RNN 的梯度消失问题，和 LSTM 减小 RNN 梯度消失的原因一样，也是因为 GRU 模型引入了门控开关(模型里面的 sigmoid 函数起着门控开关的作用)和 Hadamard 积，这可以防止对模型参数的偏导进行矩阵连乘，从而可以减小梯度消失。

注：

1. 本文用 \odot 表示 Hadamard 积，对于两个维度相同的向量 $\mathbf{a} = [a_1, a_2, \dots, a_m]^T$ 和

$\mathbf{b} = [b_1, b_2, \dots, b_m]^T$ ，则 $\mathbf{a} \odot \mathbf{b} = [a_1 b_1, a_2 b_2, \dots, a_m b_m]^T$ ；

2. 假设两个维度相同的向量 $\mathbf{y} = [y_1, y_2, \dots, y_m]^T$ 和 $\mathbf{x} = [x_1, x_2, \dots, x_m]^T$ 满足如下公式：

$$\mathbf{y} = f(\mathbf{x}) \Leftrightarrow \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix} = \begin{bmatrix} f(x_1) \\ f(x_2) \\ \vdots \\ f(x_m) \end{bmatrix}$$

则：

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} f'(x_1) \\ f'(x_2) \\ \vdots \\ f'(x_m) \end{bmatrix}$$

3. 假设两个维度相同的向量 $\mathbf{y} = [y_1, y_2, \dots, y_m]^T$ 和 $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$ 满足如下公式：

$$\mathbf{y} = \mathbf{A}_{m \times n} \mathbf{x}$$

则：

$$\begin{aligned} \frac{\partial \mathbf{y}}{\partial \mathbf{x}} &= \mathbf{A}_{m \times n}^T \\ \frac{\partial \mathbf{y}}{\partial \mathbf{A}_{m \times n}} &= \mathbf{x}^T \end{aligned}$$

4. 如果 LSTM 与 GRU 减小梯度消失原因看不懂，可以参考以下这篇文章：

<https://zhuanlan.zhihu.com/p/28297161>